

Replicação e Inferência Bayesiana sobre a Ética no Ensino Superior da Indonésia

Trabalho de Grupo realizado no âmbito da Unidade Curricular de
Modelação Bayesiana do 1º ano do Mestrado em Ciência de Dados

Diogo Freitas, 104841, MCD-LCD-A1

Diogo_Alexandre_Freitas@iscte-iul.pt

João Francisco Botas, 104782, MCD-LCD-A1

Joao_Botas@iscte-iul.pt

Miguel Gonçalves, 105944, MCD-LCD-A1

Miguel_Goncalves_Pereira@iscte-iul.pt

Ricardo Galvão, 105285, MCD-LCD-A1

Araujo_Galvao@iscte-iul.pt

Índice

1. Introdução	2
2. Dados	2
3. Modelo de medida - Análise Fatorial Confirmatória	3
3.1. <i>Student Ethics</i>	4
3.2. <i>Motivation</i>	4
3.3. <i>Self-Efficacy</i>	5
3.4. <i>Resilience</i>	5
3.5. <i>Knowledge Articulation</i>	5
3.6. <i>Team Strain</i>	6
3.7. <i>Cooperative Classroom Environment</i>	6
3.8. CFA Global	6
4. Análise <i>full</i> SEM	7
4.1. Replicação do artigo em duas etapas - CFA seguido de SEM	7
4.2. Replicação do artigo com SEM todo seguido	8
4.3. Tentativa de melhoria com <i>priors</i>	10
4.4. Resultados e comparação de modelos propostos	11
5. Deployment	13
6. Conclusão	14
Bibliografia	15
7. Anexos	16
Anexo A - Significado das variáveis	16
Anexo B - Análise descritiva dos estudantes inquiridos	18
Anexo C - Full SEM: replicação do artigo	19
1ª abordagem: Coeficientes estimados das regressões com os construtos já criados do <i>dataset</i>	19
2ª abordagem: Coeficientes estimados das regressões com a média das variáveis observadas	20
3ª abordagem: Coeficientes estimados das regressões com os <i>scores</i> das variáveis observadas	21
Anexo D - Modelo CFA Global (esquema)	22
Anexo E - Resultados do modelo SEM todo seguido	23
1 - <i>Summary</i> do modelo	23
2 - Distribuição da <i>posterior</i> para ET12 e Mot8	27
3 - BRMSEA, GammaHat, AdjBGammaHat	27

1. Introdução

O comportamento ético no contexto acadêmico é uma área de grande relevância para a promoção de comportamentos responsáveis, integridade e um ambiente educacional saudável. Compreender e modelar esses construtos éticos pode contribuir para o desenvolvimento de estratégias que promovam uma cultura de ética crescente e positiva, nas instituições de ensino superior. Com isto nasce o estudo que tem como objetivo analisar o comportamento ético de estudantes do ensino superior de Yogyakarta-Indonésia, com suporte ao artigo científico “[Data on Higher Education Student Ethics Model](#)” (Indartono, 2020).

O objetivo é replicar o modelo de equações estruturais (SEM) apresentado no artigo, mas utilizando uma abordagem Bayesiana, em vez da estatística clássica. Para isso, realizamos uma CFA individual de cada construto para avaliar a validade da estrutura teórica, seguida de uma CFA global. Posteriormente, estimamos os fatores latentes através de SEM Bayesiano, ao incorporar *priors* e a avaliar de forma mais completa a incerteza e a robustez causal dos efeitos. Também analisamos o impacto de diferentes configurações de *priors* sobre os resultados. Com isto, procuramos perceber as vantagens intrínsecas à modelação Bayesiana.

2. Dados

O conjunto de dados utilizado provém de um questionário realizado a 566 estudantes do ensino superior na Indonésia, recolhido entre julho e dezembro de 2018. Cada linha corresponde à resposta de um estudante aos 128 itens presentes que correspondem às colunas do *dataset*. Para além de algumas colunas com variáveis descritivas, como Sexo, “Tlhair” e “Pengeluaran”, temos acesso a vários itens de questões que estão separados em conjuntos/grupos, sendo estes: *Student Ethics*, *Motivation*, *Self-Efficacy*, *Resilience*, *Knowledge Articulation*, *Team Strain* e *Cooperative Classroom Environment*. Na [Figura 1](#) conseguimos perceber que o questionário abrangeu estudantes maioritariamente do sexo “1” (cerca de 76%) e com valores de IPK superiores (pela concentração de pontos, com $\approx 57\%$ para valor 4 e $\approx 41\%$ para 3). É notória a predominância de estudantes que consideram ter um nível de despesas baixo, com algumas exceções distribuídas por todos os blocos. A variabilidade entre os estudantes não é muito expressiva.




Figura 1: Distribuição da classificação Final (1–4) por Sexo (1, 2), com cores segundo o Nível de Despesas

Os conjuntos de questões mencionados foram também agrupados em construtos teóricos, utilizados na modelação proposta pelos autores do artigo original, com o objetivo de investigar os fatores que influenciam o comportamento ético dos estudantes. Cada grupo de questões é composto por um conjunto específico de itens, onde apenas alguns destes foram considerados para o construto em si, são estes: *Students Ethics* que é composto por 14 itens (ET1-ET14), dos quais só foram utilizados ET12 e ET13 pelos autores, que estão relacionados com a vivência de dilemas éticos no contexto académico; *Motivation* com 15 itens (Mot1-Mot15), onde só se utilizam os itens Mot5, Mot8 e Mot11, que captam aspetos ligados ao esforço e atitude perante o processo de aprendizagem; *Self-Efficacy* em que todos os 6 itens (SE1-SE6) foram propostos na análise dos autores e representam a confiança dos estudantes em resolução de problemas ou comunicação; *Resilience* possui 6 itens (R1-R6) e só são utilizados os itens R2, R5 e R6, que refletem como os inquiridos enfrentam falhas e obstáculos; *Knowledge Articulation*, à semelhança do *Self-Efficacy*, são também considerados todos os 5 itens (KA1-KA5) e avaliam a capacidade de expressão e partilha de conhecimento; *Team Strain* que é dividido em 17 itens (TS1-TS17) e só são utilizados os itens TS10 a TS17, que centram-se sobretudo nas dificuldades dentro de um trabalho de grupo; *Cooperative Classroom Environment* é constituído por 20 itens (CCE1-CCE20), onde foi sugerida a utilização dos itens CCE1, CCE3, CCE4, CCE5, CCE8, CCE9, CCE10 e CCE11, que representam a perceção dos estudantes sobre a cooperação nas salas de aula ([Anexo A](#)). Para além destes construtos é importante frisar que no *dataset* fornecido existiam mais grupos de questões, sendo estes POP1-POP9, PC1-PC6, Opt1-Opt6, INO1-INO5 e PDC1-PDC3. Estes itens não foram considerados para a análise porque não tínhamos contexto e nem significado certo do que elas representariam segundo o artigo.

3. Modelo de medida - Análise Fatorial Confirmatória

A Análise Fatorial Confirmatória constitui, tal como o nome indica, uma abordagem confirmatória da Análise Fatorial, cujo propósito é a avaliação, com base empírica, da adequação de relações entre os fatores latentes e as variáveis observáveis, através de uma estrutura proposta construída com o conhecimento *à priori* do investigador sobre a sua área (Brown, 2015). É possível, desta forma, representar um conjunto elevado de variáveis observáveis por meio de construtos latentes, os quais atuam como explicações subjacentes para os padrões de correlação existentes entre essas variáveis.

Esta análise é realizada, na maioria dos casos, com base na estatística frequentista. No entanto, a utilização de uma abordagem *bayesiana* oferece diversas vantagens comparativas incluindo a capacidade de lidar adequadamente com tamanhos de amostras reduzidos e a adição de informação prévia/crenças ao modelo, pelo que resulta em estimativas mais robustas e estáveis (Taylor, 2019). Além disso, esta abordagem permite a modelação de variáveis ordinais ou com distribuições não normais; possibilitando também a utilização de relações cruzadas e estruturas hierárquicas mais sofisticadas. Os testes de ajustamento do modelo, os quais, na inferência bayesiana, podem ser conduzidos por meio de métricas baseadas na distribuição *à posteriori* e em simulações preditivas, oferecem diagnósticos mais sensíveis e informativos quanto à adequação do modelo aos dados observados.

Para verificar a adequabilidade dos construtos sugeridos pelos autores (mencionados na [Secção 2](#)), foram efetuadas CFA para cada construto individualmente, através de 3 fases, e posteriormente realizada uma CFA global (com toda a formação dos construtos em simultâneo).

1. CFA para todas as variáveis observadas, a fim de ver se a seleção dos autores faz sentido;
2. CFA apenas para as variáveis selecionadas no artigo;
3. CFA com uma sugestão nossa com base nas interpretações das 2 anteriores (não foi aplicável a todas).

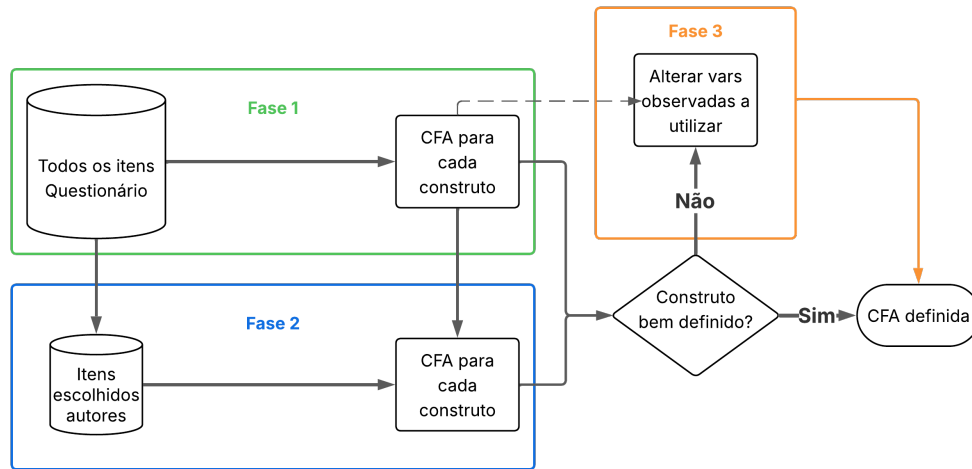


Figura 2: Diagrama com o fluxo efetuado para avaliar e justificar a CFA de cada conjunto de itens

Para todos os passos e para cada CFA, foi adotada uma abordagem bayesiana com estimação em Cadeias de Markov Monte Carlo (MCMC). Por sua vez, estas consistem em três cadeias com um *burn-in* de 1500 iterações e uma amostra posterior de 3000 iterações, que possibilitam a convergência e a precisão das estimativas. Para esta análise foram usadas distribuições *a priori* não informativas para os *loadings* $X \sim N(0, 10)$ e para as variâncias $X \sim \gamma(1, 0.5)$.

3.1. Student Ethics

O construto *Student Ethics*, na primeira análise, contém 14 variáveis observadas (ET1-ET14). Para o teste que contempla todas as variáveis, as que têm valores de *loadings* bem mais expressivos que as restantes são a ET12: 0.741 e ET13: 0.748, pelo que coincide com a sugestão dos autores na escolha dos itens. Apesar da conclusão ser a mesma, os valores são distintos aos apresentados no artigo. Os valores de R^2 são de 0.609 e 0.632, respetivamente, indicando que uma proporção substancial da variância das variáveis observadas é explicada pelo fator latente, sendo que, desta forma, todas as variáveis têm uma forte correlação com a variável latente. Os \hat{R} têm todos os valores próximos de 1, o que indica uma boa convergência das cadeias MCMC e, portanto, estabilidade nas estimativas dos parâmetros.

Na segunda análise, com a seleção das variáveis ET12 e ET13, temos um modelo CFA com apenas duas variáveis. Este modelo tem 0 graus de liberdade, pelo que o modelo é saturado e, por isso, ajusta-se perfeitamente aos dados observados. Isto não será um problema para as fases seguintes ao testarmos com o CFA global e com o SEM porque o modelo terá muito mais parâmetros, mas torna limitada a análise por si só.

A 3ª análise acaba por não ter efeito para este construto, pois concordamos com as escolhas dos autores e não propomos mudanças nos itens utilizados.

3.2. Motivation

Para a *Motivation* temos 15 itens (Mot1-Mot15) e notamos que o artigo opta pelos Mot5, Mot8 e Mot11. Ao realizar o CFA com todas as variáveis vemos que estas três, a par do Mot15, são as únicas que possuem valores negativos de *loadings*. Talvez os autores tenham optado por incluir as negativas porque queriam

captar a informação destas perguntas do questionário ou não queriam uma influência grande de esforço na aprendizagem. A exclusão de Mot15 pode ser explicada por um valor negativo mais expressivo (-0.165) que os restantes ($[-0.101, -0.058]$). Os valores de \hat{R} estão próximos de 1, que é bom sinal.

Ao realizarmos o modelo com Mot5, Mot8 e Mot11 reparamos que o construto fica bem definido com a subida do PPP¹ de 0 para 0.508, valor desejável para a adequabilidade do modelo aos dados, para além de ter valores de R^2 e *loadings* bastante sólidos. Assim, permanecemos com estes 3 itens e a 3ª etapa fica sem efeito.

3.3. *Self-Efficacy*

No *Self-Efficacy* os autores optaram por utilizar todos os itens (SE1-SE6) e, ao fazermos o modelo com todos, acabamos por concordar, visto que os *loadings* são todos maiores que 0.4. Para além disso, os \hat{R} têm todos valores próximos de 1 e os valores de R^2 variam entre 0.333 (SE1) e 0.581 (SE3) que indica que os itens têm boa explicabilidade pela variável latente.

Com uma boa adequação do modelo com as 6 variáveis, apesar do valor nulo do PPP, torna-se desnecessário prosseguir para a fase 2 (reformulação do modelo para as escolhas efetuadas) e a fase 3 (avaliação da formação do construto), uma vez que os resultados já evidenciam um construto bem definido e estatisticamente consistente.

3.4. *Resilience*

Para o construto da *Resilience* que inicialmente tem 6 itens (R1-R6), fez-se o mesmo procedimento com todas as variáveis. Os autores optam por utilizar apenas os itens R2, R5 e R6 que, pelos valores de *loadings* obtidos, é bastante coerente com análise se utilizássemos um corte de *loadings* acima de 0.45. À semelhança dos construtos anteriores, os valores de \hat{R} e R^2 são bem definidos, sendo 1 para todos e > 0.4 para as variáveis a considerar, respetivamente.

Na fase 2 fazemos uma análise destes 3 itens e percebemos que os *loadings* são 0.394, 0.692 e 0.556, para R2, R5 e R6, respetivamente. O valor do PPP passou de 0 a 0.494, pelo que o modelo recente é adequado aos dados. Apesar dos valores serem altos e dos coeficientes de determinação (R^2) assumirem um “fit” razoável (> 0.25), reparamos que R2 ficou abaixo dos outros 2 itens, com esta CFA dos autores. Foi com esta hipótese que prosseguimos para uma análise sem o item R2, mantendo apenas R5 e R6 para a fase 3.

Na fase 3 o modelo CFA teve melhorias significativas, porém, em conformidade com o construto de *Student Ethics*, esta análise torna-se difícil de ser interpretada e comparada com a anterior, por conta dos graus de liberdade do modelo (dois itens \rightarrow R2 e R5). Mesmo que a remoção deste item (R2) trouxesse vantagens futuras, decidimos permanecer com R2, R5 e R6 para não sairmos muito da linha de raciocínio dos autores apenas por um item que pode ter um significado elevado do ponto de vista interpretativo.

3.5. *Knowledge Articulation*

No construto *Knowledge Articulation* são utilizados os itens (KA1-KA5) assim como no artigo original, por todos os seus *loadings* serem superiores a 0.4. Os seus valores de \hat{R} estão próximos de 1 e os valores de R^2 estão próximos de 0.5 para todas as variáveis, como já foi mencionado é um resultado positivo e desejável.

Novamente, apesar do valor de PPP ser nulo, há evidências de um construto bem definido. Para além de toda a análise inerente dos *loadings*, é necessário perceber que as decisões dos autores são mais

¹Posterior Predictive P-value

fundamentadas e têm um peso grande para a análise. Assim, as seguintes fases são desnecessárias para este construto.

3.6. *Team Strain*

O *Team Strain* utiliza os itens (TS1-TS17), os autores usam as variáveis (TS10-TS17) que apresentam *loadings* superiores a 0.45, exceto a variável TS17 que apresenta valor de 0.449. Na escolha destas variáveis concordamos com os autores. Embora seja possível adicionar a variável TS9 por esta ser superior a um limite definido de 0.4, decidimos mais uma vez manter as variáveis originais, atendendo ao facto de possuímos menos conhecimento sobre o questionário original. A pergunta do item TS9 é desconhecida para nós e não é descrita no artigo.

Na reformulação do modelo que incluiu os itens TS10 a TS17, os valores dos *loadings* foram altos, que reflete numa forte associação entre as variáveis observadas e o fator latente. Os indicadores de convergência, como o valor de \hat{R} , e a variância explicada (R^2), apresentaram apenas alterações marginais, tanto positivas, como negativas, o que sugere uma estabilidade dos parâmetros do modelo face à inclusão dos novos itens. Contudo, o valor de PPP não se alterou com o novo modelo. Ainda assim, a consistência dos indicadores estatísticos e a manutenção de boas propriedades métricas reforçam a conclusão de que o construto é bem definido e estatisticamente robusto.

3.7. *Cooperative Classroom Environment*

Ao analisar os *loadings* obtidos para o construto *Cooperative Classroom Environment*, das variáveis CCE1-CCE20 foram destacadas as seguintes, com base nos seus *loadings*: CCE1, CCE5, CCE10, CCE11, CCE16, CCE17, CCE18, CCE19. Os valores de \hat{R} estão próximos de 1 para todas as variáveis e têm um R^2 bom ou muito bom para todas as variáveis, variando entre 0.363 (CCE11) e 0.569 (CCE16), pelo que é conferido um bom ajuste.

No entanto, há um grande contraste com as variáveis escolhidas pelos autores: CCE1, CCE3, CCE4, CCE5, CCE8, CCE9, CCE10, CCE11. Analisando os *loadings* obtidos, na fase 2, existiu uma grande melhoria em comparação com os valores obtidos por estas variáveis na primeira experiência, assim como, nos seus valores de R^2 ; os valores de \hat{R} permanecem iguais. Embora a escolha de variáveis não possa ser justificada pela nossa análise, numa análise completa, o construto criado tem resultados bons e consistentes.

Por outro lado, na fase 3 foi feita a seleção mencionada a partir dos *loadings* destacados da fase 1. Os resultados obtidos pela nossa escolha são comparativamente inferiores aos *loadings* dos autores e possuem um R^2 bipartido, ou seja, as variáveis (CCE16-CCE19) são muito bem explicadas pelo construto (com valores de $R^2 > 0.6$), mas que não oferecem uma boa explicação para as restantes (com valores de $R^2 < 0.3$).

Este cenário reforça a importância do conhecimento de contexto e do caso empírico original, como o detido pelos autores, para orientar decisões fundamentadas na construção do modelo e seleção de variáveis. Deste modo, vamos utilizar a escolha dos autores, tanto pela modelação mais robusta, quanto pela explicabilidade

3.8. CFA Global

Após a análise separada de cada construto como forma de justificar escolhas dos autores e de ver outros itens que poderiam ser interessantes, passamos para um modelo CFA Global ([Anexo D](#)). A conclusão a que chegamos é que todas as questões consideradas para os construtos são bem fundamentadas e suportadas

pelos valores de *loadings*. Por essa razão, vamos aceitar todos os itens e seguir por um fio de replicar na exatidão o modelo dos autores, com outras propostas de melhorias que não passem por alterar variáveis.

No modelo com todos os construtos, criados a partir dos itens dos autores, os resultados evidenciaram uma forte correlação entre as variáveis manifestas e as latentes e com valores de \hat{R} próximos de 1. O modelo foi estimado através do método de otimização MCMC, utilizando 500 iterações de *burn-in* e 1500 iterações de amostragem, o que permitiu uma convergência robusta dos parâmetros. Os *loadings* têm todos valores superiores a 0.409 (da variável R2), sendo o maior o item ET12 com 0.915, com um intervalo de credibilidade de [0.833, 0.989] a 95%. Relativamente às covariâncias entre latentes, temos a presença de valores positivos e negativos a variar de -0.170 (Mot com KA) a 0.467 (KA com TS), que mostram uma inter-relação coerente entre os construtos e que estes não apenas se influenciam mutuamente, mas também refletem a complexidade e a natureza multifacetada das suas dinâmicas. O valor do PPP é nulo, o que pode sinalizar limitações no ajustamento global do modelo, mesmo este tendo complexidade alta.

Assim, podemos concluir que esta CFA global valida os resultados obtidos nas análises individuais de cada construto, que sustenta a consistência e fundamentação teórica. As covariâncias entre as latentes reforçam a robustez do modelo proposto pelos autores, onde prevalece a coerência interna e a qualidade da estrutura latente avaliada. Apesar do valor nulo do PPP sugerir possíveis limitações no ajustamento global, os indicadores globais de qualidade do modelo sustentam a solidez teórica e estatística do modelo replicado.

4. Análise *full* SEM

Os Structural Equation Models (SEM) constituem uma classe de metodologias, muito conhecidas em ciências sociais, que permitem representar relações entre variáveis observáveis e fatores latentes, bem como entre fatores latentes (Kaplan, 2001). Esta formulação é ainda mais beneficiada pela modelação bayesiana porque centra-se nas observações individuais *raw* e na estimação direta das variáveis latentes, ao invés de ter o modelo de regressão clássico ou de obter os *scores* antes das regressões (em duas etapas). Além disso, fornece uma interpretação mais direta através de equações de regressão familiares, possibilita a utilização de *priors* informativas com base no conhecimento prévio, e produz estimativas mais robustas, especialmente em amostras pequenas, ao fornecer estatísticas úteis como médias e percentis da distribuição *a posteriori* (Hayashi, 2008).

É através disto que foram realizadas várias experiências que procuram utilizar de inferência bayesiana para replicar o artigo estudado e a tentativa de melhorar os resultados das regressões. Nos testes destas secções foi utilizado um estimador de Bayes e um método otimizador MCMC (Markov Chains) com 3 cadeias, um *burn-in* de 500 iterações e 1500 iterações de estimações da amostra. Embora este número total de iterações (2000) possa ser considerado relativamente modesto, revelou-se suficiente para garantir a convergência dos parâmetros e uma boa precisão nas estimativas. Também vai ser relevante para comparar modelos com diferentes *priors*, pela complexidade temporal do algoritmo.

4.1. Replicação do artigo em duas etapas - CFA seguido de SEM


Num primeiro momento, de modo a replicar o artigo, fomos utilizar os construtos criados pelos autores que o próprio *dataset* contém, onde nos apercebemos que apenas realizaram a média dos itens que haviam selecionado para os construtos, e não os valores dos *scores*. Ou seja, toda a análise de *loadings* presentes no

artigo foi apenas relevante para escolher os itens a considerar e não a extrair os valores dos *scores*. Num exemplo prático, para o construto de *Student Ethics* foi optado por incluir apenas os itens ET12 e ET13, então o valor deste construto para cada linha correspondia a $\frac{ET12+ET13}{2}$.

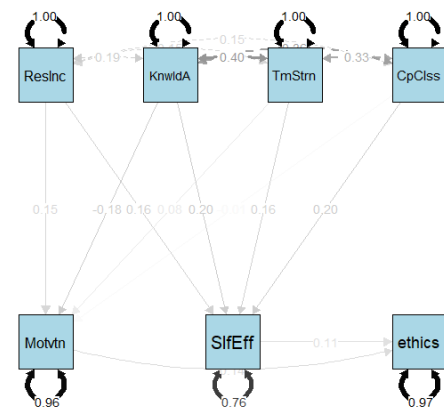
Nesta linha vamos considerar três abordagens que são: (1) utilizar os construtos dos autores do *dataset*; (2) fazer a nossa própria média dos itens, tal como o artigo sugere; (3) realizar ainda a estimação do modelo com os *scores* dos construtos criados. Para cada uma das 3 abordagens utilizamos *priors* não informativas $X \sim N(0, 10)$ nos *loadings* e $X \sim \gamma(1, 0.5)$ nas variâncias (as pré-definidas pela função).

Os resultados das estimações para as duas primeiras abordagens foram quase idênticas às apresentadas pelo artigo, o que prova que os resultados, para além de fidedignos com a metodologia adotada das médias, também consegue ser estimado com Bayes, que tem todas as vantagens já mencionadas. Ainda assim a 2ª abordagem, que utiliza médias calculadas diretamente, mostrou-se ligeiramente mais precisa em relação aos valores do artigo, possivelmente devido à utilização de todas as casas decimais na média dos itens. Já a 3ª abordagem, baseada nos *scores* dos construtos, apresentou resultados menos semelhantes aos do artigo, que pode estar relacionado com a própria natureza processada dessas variáveis e a sensibilidade da estimação aos *scores* latentes, ao invés da simplicidade das médias. Também de destacar que, nas três abordagens, os valores de \hat{R} estão todos próximos de 1, que indica boa convergência dos modelos estimados e reforça a fiabilidade dos resultados obtidos (ver [Anexo C](#)).

É importante de reforçar que, apesar de estarmos a reduzir a informação de várias variáveis observáveis para uma só, acabamos por estar a utilizar uma variável observável “resumida” para estimar os resultados das regressões. Ou seja, apesar de serem teoricamente construtos, para o modelo continuam a ser consideradas como variáveis manifestas (representados por quadrados em assunções literárias, como representado na [Figura 3](#)). Neste sentido, os resultados e os valores das métricas de critérios de informação não são comparáveis com as abordagens seguintes do *full SEM*.



(a) Modelo do artigo (Fig. 1.)



(b) SEM - replicação do artigo com o nosso modelo

Figura 3: Regressões entre construtos

4.2. Replicação do artigo com SEM todo seguido

De forma a colmatar a limitação associada à abordagem em duas etapas - na qual os autores inicialmente realizaram uma CFA para estimar os construtos latentes, e posteriormente utilizaram as médias como variáveis observadas em modelos de regressão separados - optámos por estimar um modelo SEM completo, que integra simultaneamente o modelo de medida e o modelo estrutural. Isto traz vantagens do ponto de

vista da abordagem bayesiana porque: evita o tratamento de médias e *scores* como variáveis observadas, que pode induzir num erro de medição e comprometer os coeficientes a estimar; preserva a natureza latente dos construtos ao especificar que existe uma incerteza associada e que é incluída diretamente nos efeitos estruturais; e permite que o modelo ajuste todos os parâmetros em simultâneo (como *loadings*, variâncias e covariâncias). Ademais, é bem mais robusto e completo porque permite a incorporação de conhecimento à *priori* e dá uma visão mais rica sobre a incerteza dos parâmetros estimados, ao fornecer intervalos de credibilidade que indicam, não apenas os valores mais prováveis, mas também os limites inferior e superior plausíveis para cada parâmetro, permitindo afirmar, por exemplo, que 95% das amostras geradas pelo modelo encontram-se dentro desse intervalo.

Com base nestes princípios, implementámos um modelo SEM unificado que inclui, tanto o modelo de medida (CFA para cada construto), como o modelo estrutural, onde se especificam as relações entre os construtos (Figura 4). Para isso, num primeiro momento, foram utilizados os construtos sugeridos pelos autores, já que os indicadores foram previamente validados e demonstraram consistência, e com *priors flat*/ não informativas².

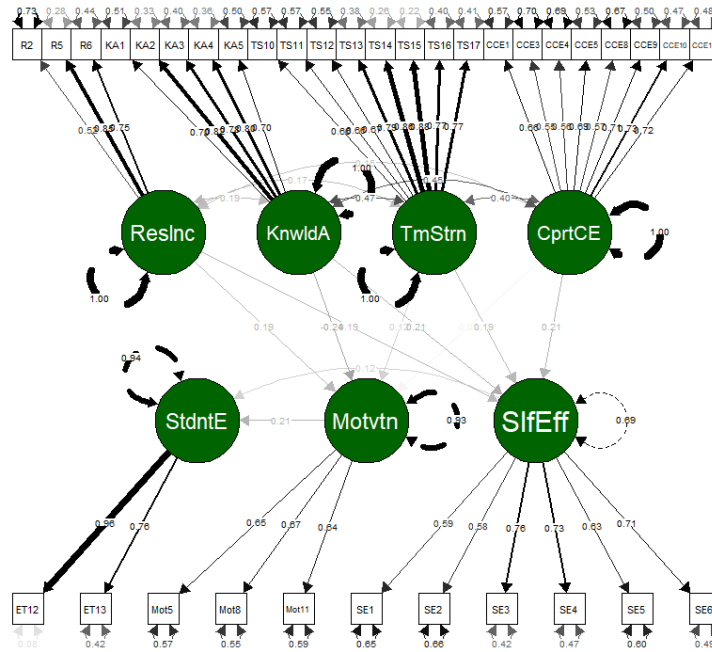


Figura 4: Modelo SEM seguido com fatores latentes estimados (círculos) através das variáveis observadas (quadrados)

Quanto aos resultados obtidos, estes foram concordantes com os obtidos pelos autores, nos *loadings* (λ) e nos coeficientes das regressões β entre os construtos, com a ressalva que estamos a utilizar Bayes, resultando naturalmente em valores ligeiramente diferentes. Por exemplo, (λ) da variável observada TS10, associada ao construto *TeamStrain*, foi estimado em 0.483, com um desvio padrão de 0.029 e um intervalo de credibilidade a 95% entre 0.428 e 0.538, que evidencia uma relação substancial e estatisticamente credível com o fator latente. Depois, o fator *TeamStrain* demonstrou contribuir para a explicação da variável dependente *Motivation*, com uma estimativa de regressão de 0.126 (parecido ao do artigo) e com um intervalo de credibilidade a 95% ([0.001,

² $X \sim N(0, 10)$ nos *loadings* e $X \sim \gamma(1, 0.5)$ nas variâncias

0.259]), o que sugere uma relação positiva, porém fraca e estatisticamente incerta. O valor padronizado da estimativa (0.122) mostra uma tendência de associação positiva (Anexo E1).

Adicionalmente, todos os valores de \hat{R} obtidos situaram-se muito próximos de 1 (ex., 1.002 ou inferiores). As variâncias *a posteriori* dos parâmetros revelaram-se estáveis, sem evidência de dispersões excessivas, o que contribui para a robustez do modelo. Indicadores de qualidade do modelo, como o BRMSEA (0.072) e o $\hat{\gamma}$ (0.884), apontam para um ajuste satisfatório, pelo que reforçam a fiabilidade da estimação Bayesiana (ver Anexo E3). Estes indicadores, em conjunto, sugerem que a estimação completa do modelo SEM bayesiano não só reproduz com rigor os resultados anteriormente obtidos, como oferece maior transparência e nuance na interpretação dos efeitos e relações entre os construtos.

Para além deste modelo SEM seguido, foi também realizado um que utilizava as variáveis observadas sugeridas por nós para os construtos de *Resilience* e *Cooperative Classroom Environment*. Os resultados e as métricas foram bastante parecidos e por isso foi decidido realizar apenas as tentativas de melhoria com *priors* para os itens sugeridos pelo artigo, que já foram provados que fazem sentido para a análise.

4.3. Tentativa de melhoria com *priors*

Para esta etapa, fomos à procura de melhorar os resultados da primeira proposta do SEM seguido, que vamos designar de SEM_{base}. A utilização de *priors* mais restritas na abordagem Bayesiana permite incorporar conhecimento prévio e refinar as estimativas para estas estarem mais coerentes com a realidade. No entanto, para esta análise que se segue, é importante termos cuidado, pois estas *priors* podem refletir crenças erradas ou desatualizadas, o que pode enviesar os resultados. As sugestões que fazemos a ajustar as *priors* é com base nas indicações do artigo e na análise SEM feita até então, realizadas de forma criteriosa, com vista a melhorar a robustez do modelo e sem comprometer a sua validade.

Foram realizados 3 modelos com ajustes de *priors* e foi dado um nome a cada um de forma a ficar mais intuitivo. Estes modelos são os seguintes:

- SEM_{priors} → Para este modelo decidimos restringir todos os valores de λ - tinham valores que variavam de 0.3 a 0.6 (1) - exceto para ET12 e ET13 - com valores mais expressivos nos *loadings* (2) ([0.75,1.0] e [0.6, 0.83], respetivamente) - quer no artigo, quer no modelo SEM. Também utilizamos uma distribuição que apenas alterava o σ de 10 para 0.25 dos β das regressões (3);

$$\lambda \sim N(0.5, 0.1) \quad (1)$$

$$\lambda_{ET12} \sim N(0.85, 0.05) \quad (2)$$

$$\lambda_{ET13} \sim N(0.7, 0.05)$$

$$\beta \sim N(0, 0.25) \quad (3)$$

- SEM_{priors_reg0} → Ao observarmos os coeficientes de regressões do artigo e os que obtivemos no modelo SEM, percebemos que a regressão “Cooperative Classroom Environment → Motivation” tinha um valor bastante próximo de 0 (-0.014). Foi através desta hipótese que decidimos propor uma *prior* que tornava este β a um valor muito próximo de 0, através de uma distribuição normal centrada em 0 ($\mu = 0$) e com um desvio padrão muito pequeno (4). Este modelo apenas altera os valores de β para esta regressão;

$$\beta_{\text{Cooperative Classroom Environment} \rightarrow \text{Motivation}} \sim N(0, 0.001) \quad (4)$$

- $SEM_{priors_all} \rightarrow$ Para um último modelo decidimos juntar as *priors* de SEM_{priors} e SEM_{priors_reg0} para tentar comparar se, ao complementarmos as informações, conseguíamos obter estimativas melhores. Os valores de γ permaneceram-se inalterados para estes 3 modelos.

Os resultados destes modelos revelaram estimações parecidas com o do modelo apresentado na [Secção 4.2](#), com a exceção que os intervalos estão ajustados e mais restritos de acordo com as *priors* utilizadas. Os valores de \hat{R} continuaram a ser bastante próximos de 1 e os coeficientes supomos que estão mais próximos da realidade, por não possuírem um desvio padrão tão alto da *prior flat* $N \sim (0, 10)$.

4.4. Resultados e comparação de modelos propostos

A fim de concluir qual dos modelos abordados nas secções anteriores teve um ajuste melhor aos dados observados. As métricas a estudar fazem uma espécie de *trade-off* entre as estimações e ajuste, com a complexidade dos modelos. A [Tabela 1](#) mostra várias métricas de desempenho para as diferentes versões do modelo SEM, comentados e explicados na [Secção 4.3](#).

Tabela 1: Comparação de métricas entre os diferentes modelos SEM (valores atualizados)

Modelo	logl \uparrow	bic \downarrow	dic \downarrow	waic \downarrow	se_waic \downarrow	looic \downarrow	se_loo \downarrow	margloglik \uparrow
SEM_{base}	-17397.79	35340.55	34965.83	35076.15	709.32	35075.11	708.53	-17811.33
SEM_{priors}	-17399.31	35343.58	34960.74	35069.99	708.68	35067.51	707.72	-17626.16
SEM_{priors_reg0}	-17397.83	35340.63	34963.81	35079.03	711.15	35072.32	708.48	-17805.49
SEM_{priors_all}	-17399.15	35343.26	34959.93	35069.46	709.01	35066.1	707.78	-17622.93

A primeira métrica analisada é a logl (Log-Verossimilhança), que avalia quão bem o modelo explica os dados observados. Valores mais elevados (ou menos negativos) indicam um melhor ajustamento ao conjunto de dados. Os resultados indicam que o modelo SEM_{base} apresenta o melhor desempenho neste critério, refletindo o ajustamento mais eficaz entre os modelos comparados. Em contraste, o modelo SEM_{priors} evidencia o pior desempenho, o que poderá sugerir numa menor adequação aos dados, possivelmente devido à utilização de *priors* excessivamente restritivos.

Contudo, a Log-Verossimilhança não penaliza a complexidade do modelo. Para tal, recorre-se ao BIC (Bayesian Information Criteria) (5), que introduz uma penalização proporcional ao número de parâmetros estimados:

$$BIC = -2 \cdot \log(L) + k \cdot \log(n) \quad (5)$$

O BIC permite equilibrar o compromisso entre qualidade de ajustamento e simplicidade do modelo. Nesta métrica, o modelo SEM_{base} continua a destacar-se como o mais favorável, pelo que reforça a sua robustez. Por outro lado, o modelo SEM_{priors} permanece como o menos vantajoso, o que poderá dever-se à complexidade acrescida introduzida pelas *priors*. É ainda relevante notar que o modelo SEM_{priors_all} também apresenta um valor de BIC elevado (muito próximo do SEM_{priors}), o que sugere que estes dois modelos mais complexos foram os mais penalizados nesta métrica.

A métrica DIC (Deviance Information Criteria) (6) segue uma lógica semelhante à do BIC, mas está especialmente adaptada ao contexto *bayesiano*, incorporando a incerteza dos parâmetros estimados ao penalizar a complexidade do modelo:

$$DIC = E[D(\theta)] + p_D \quad (6)$$

Enquanto o BIC penaliza apenas com base no número de parâmetros e no tamanho da amostra (via $k \log(n)$), o DIC considera também a diferença entre a média da *deviance* e a *deviance* avaliada nos parâmetros médios. Nesta perspectiva, o modelo SEM_{priors_all} destaca-se como o mais adequado, ao passo que o modelo SEM_{base} revela o pior desempenho. Este resultado poderá indicar que as *priors* utilizadas em SEM_{priors_all} traduzem conhecimento prévio válido, permitindo ao modelo ganhar em eficiência e precisão, sem sacrificar a capacidade de generalização. De igual modo, o modelo SEM_{priors} apresenta valores muito próximos dos de SEM_{priors_all} , que sustenta esta conclusão.

De seguida, analisamos o WAIC (Widely Applicable Information Criteria) (7), também “enraizado” na perspectiva *bayesiana* e centrado na capacidade preditiva dos modelos, integrando a incerteza associada aos parâmetros:

$$WAIC = -2 \left(\sum_i \log(E_\theta[p(y_i|\theta)]) - \sum_i \text{Var}_\theta(\log p(y_i|\theta)) \right) \quad (7)$$

Valores mais baixos de WAIC refletem melhor desempenho. Nesta métrica, o modelo SEM_{priors_all} volta a destacar-se como o melhor, enquanto o modelo SEM_{priors_reg0} surge como o menos eficaz. Esta conclusão é complementada pela análise do *se_WAIC* (Erro-Padrão do WAIC), que quantifica a variabilidade da estimativa do WAIC. Valores mais baixos sugerem maior estabilidade e confiança nos resultados. Mais uma vez, o modelo SEM_{priors_reg0} mantém-se como o menos robusto. No que respeita ao modelo mais robusto, apesar de o SEM_{priors_all} apresentar o melhor valor absoluto de WAIC, o modelo SEM_{priors} possui um valor extremamente próximo. Importa referir que o *se_WAIC* mais reduzido do SEM_{priors} confere-lhe maior fiabilidade, podendo este ser considerado, neste critério, o modelo mais robusto.

De forma análoga ao WAIC, o LOOIC (Leave-One-Out Information Criteria) avalia a capacidade preditiva dos modelos com base numa validação cruzada *leave-one-out*. Esta métrica estima o desempenho do modelo em dados não observados e dá uma aproximação ao erro de predição fora da amostra. Os resultados seguem uma tendência semelhante às métricas anteriores: o modelo SEM_{priors_all} apresenta o melhor desempenho, seguido de perto pelo modelo SEM_{priors} . Por sua vez, o modelo SEM_{base} apresenta o pior resultado, demonstrando que a inclusão de *priors* melhora substancialmente a capacidade preditiva dos modelos. O *se_LOO* reforça estas conclusões, quantificando a incerteza associada ao LOOIC – uma vez mais, com o modelo SEM_{priors} a evidenciar menor variabilidade, o que fortalece a sua consistência.

Por fim, analisamos a *margloglik* (Marginal Log-Likelihood), uma métrica fundamental na comparação de modelos bayesianos, pois incorpora a evidência fornecida pelos dados a favor de um modelo, integrado sobre os parâmetros:

$$\log p(y|M) = \log \int p(y|\theta, M)p(\theta|M)d\theta \quad (8)$$

Valores mais elevados indicam maior suporte aos dados por parte do modelo. Neste critério, o modelo SEM_{priors_all} apresenta o melhor desempenho, sugerindo que a especificação conjunta dos *priors* foi a mais eficaz em capturar a estrutura subjacente aos dados. Em contrapartida, o modelo SEM_{base} apresenta o pior valor, o que era de esperar dado que não incorpora qualquer informação prévia, limitando assim a sua capacidade de generalização no enquadramento *bayesiano*.

Portanto, podemos concluir que as métricas mais básicas, não especificamente desenhadas para o contexto *bayesiano*, tendem a favorecer o modelo SEM_{base} , atribuindo-lhe maior relevância e robustez/complexidade, o que acaba por penalizar a avaliação dos modelos com *priors*. Por outro lado, as métricas com maior afinidade ao enquadramento *bayesiano* apresentam resultados contrários, favorecendo os modelos com *priors*. Ainda assim, é fundamental definir *priors* de forma adequada, sendo o modelo SEM_{priors_reg0} um exemplo em que as *priors* aplicadas não contribuem significativamente para o desempenho do modelo. Assim, a escolha do melhor modelo restringe-se a dois candidatos: SEM_{priors} e SEM_{priors_all} . O primeiro destaca-se por apresentar bons resultados com a menor variância entre execuções, enquanto o segundo alcança os melhores resultados globais, embora com alguma variabilidade nos desempenhos obtidos. Estes dois modelos têm a ligeira diferença da inclusão da regressão “Cooperative Classroom Environment → Motivation” ser praticamente centrada a 0.

5. Deployment

Fora estes testes explicitados, surgiu a ideia de realizar-se uma aplicação em Rshiny para complementar a nossa análise, de modo a fazermos outras execuções dos modelos com uma UI mais “amigável”. Esta aplicação pode ser consultada através do seguinte [link](#), que contém 3 *tabs* principais, cada uma com 2 *subtabs*:

- **EDA**: fazer uma pequena análise exploratória dos dados adquiridos e das questões colocadas no inquérito.
 - **Dados**: permite ver a distribuição de cada uma das variáveis citadas no decorrer do projeto, bem como o texto das questões e tabela de dados geral;
 - **Construtos**: criar construtos com base nas variáveis que o utilizador seleciona e ver a matriz de correlação, *alpha* de Cronbach e *loadings*;
- **Replicação do artigo**: procura replicar o artigo com as suposições tomadas pelos autores³.
 - **CFA Bayesiana separada**: permite replicar a análise separada realizada na [Secção 3](#), de forma a ser mais fácil de fazer testes e comprovar resultados e decisões;
 - **SEM c/ CFA ou Média por Construto antes**: permite replicar o SEM como os autores sugerem (mostrado na [Secção 4.1](#)), através de CFA que atuam como variáveis manifestas. Pode ser escolhido método pela média ou pelos *scores* e controladas as variáveis latentes;
- **Full SEM + melhorias**: é a *tab* que contém os códigos e respetivos *outputs* do trabalho realizado (em formato html).
 - **Full SEM - com e sem priors**: tem o código corrido para os modelos SEM com tudo seguido (*priors flat* e *priors informativas*);
 - **Código completo**: corresponde a todo o código corrido para a análise e discussão de resultados deste relatório. Esta *tab* serve como um guia e como anexo.

O repositório deste projeto pode ser encontrado no seguinte link: <https://github.com/GothamAnalytics-7/Modelacao-Bayesiana>.

³É possível que o servidor dê *disconnect* na execução dos modelos por conta da pouca memória disponível na versão gratuita do shiny.

6. Conclusão

Este trabalho teve como principal objetivo replicar o modelo de equações estruturais do artigo [Data on Higher Education Student Ethics Model](#) (Indartono, 2020), através de uma abordagem Bayesiana. Para isso, foi realizada uma análise fatorial confirmatória (CFA) individual de cada construto, seguida de uma CFA global. Os resultados obtidos confirmaram a validade da estrutura teórica dos construtos definidos pelos autores, com *loadings* elevados, valores de \hat{R} próximos de 1 e o coeficiente de determinação (R^2) consistentes, o que demonstra convergência e robustez estatística. As covariâncias entre os fatores latentes revelaram relações coerentes com a teoria e refletiram a complexidade das dinâmicas entre os construtos éticos em contexto acadêmico. Apesar do valor nulo do Posterior Predictive P-value (PPP) em alguns modelos indicar limitações no ajustamento global, os restantes indicadores apontaram para uma boa adequação da estrutura latente aos dados.

Posteriormente, foi realizada a estimação de modelos SEM completos. Foram efetuadas diferentes abordagens nesta fase para estar em conformidade com o trabalho desenvolvido pelos autores, mas acrescentando uma perspetiva Bayesiana com *priors flats*, numa primeira análise, seguida de *priors* mais restritivas e informativas.

As vantagens da modelação Bayesiana foram claras. A sua utilização permitiu uma avaliação mais completa da incerteza, através da estimação dos parâmetros e da análise das distribuições *a posteriori*, e possibilitou a incorporação de conhecimento prévio por meio da adição de diferentes *priors* aos modelos realizados. Com isto, foi possível comparar modelos e concluir que, em algumas configurações, as *priors* melhoraram a estabilidade e precisão das estimativas, sem comprometer a validade do modelo, ainda que os valores fossem bastante parecidos. Por exemplo, ao aplicarmos uma *prior* com distribuição normal centrada em 0 para um β de uma regressão, através de crenças e conhecimento prévio, observamos uma redução nas estimativas e um melhor ajuste. Isto reforça a robustez dos parâmetros e evidencia o contributo das *priors* informativas para a estabilidade do modelo.

Concluimos, assim, que a replicação do artigo foi bem sucedida, e que a abordagem Bayesiana aplicada não só valida os resultados do estudo original, como também acrescenta valor em termos de inferência estatística e compreensão das relações entre os fatores que influenciam o comportamento ético dos estudantes do ensino superior.

Bibliografia

- Brown, T. A. (2015). Confirmatory factor analysis for applied research, 2nd ed. *Confirmatory factor analysis for applied research, 2nd ed.*, xvii, 462–xvii, 462.
- Hayashi, K. (2008). Structural Equation Modeling: A Bayesian Approach. Sik-Yum Lee. New York: Wiley, 2007, 432 pages, \$130.00 (Hardcover). *Structural Equation Modeling: A Multidisciplinary Journal*, 15(3), 534–540. <https://doi.org/10.1080/10705510802154356>
- Indartono, S. (2020). Data on higher education student ethics model. *Data in Brief*, 28, 104904. <https://doi.org/https://doi.org/10.1016/j.dib.2019.104904>
- Kaplan, D. (2001). Structural Equation Modeling. Em N. J. Smelser & P. B. Baltes (eds.), *International Encyclopedia of the Social & Behavioral Sciences: International Encyclopedia of the Social & Behavioral Sciences* (pp. 15215–15222). Pergamon. <https://doi.org/https://doi.org/10.1016/B0-08-043076-7/00776-2>
- Merkle, E. C., Fitzsimmons, E., Uanhoro, J., & Goodrich, B. (2021). Efficient Bayesian Structural Equation Modeling in Stan. *Journal of Statistical Software*, 100(6), 1–22. <https://doi.org/10.18637/jss.v100.i06>
- Taylor, J. M. (2019). *Overview and Illustration of Bayesian Confirmatory Factor Analysis with Ordinal Indicators*. <https://doi.org/https://doi.org/10.7275/vk6g-0075>

7. Anexos

Anexo A - Significado das variáveis

Tabela 2: Descrição das variáveis sugeridas pelos autores a utilizar nos construtos

Nome do Construto	Itens a utilizar
Student Ethics	<p>ET12: I personally dealt with ethical dilemmas while studying at university.</p> <p>ET13: I have been confronted with ethical dilemmas during my studies at university.</p>
Motivation	<p>Mot5: In terms of effort, I rarely try my best.</p> <p>Mot8: When my teacher asks a question in class, I never volunteer to answer.</p> <p>Mot11: If I do not understand something on my homework, the first thing I do is skip it.</p>
Self Efficacy	<p>SE1: I feel confident analysing the long-term problem of finding a solution in my study.</p> <p>SE2: I feel confident representing my department at various events.</p> <p>SE3: I feel confident contributing to the discussion of learning strategies.</p> <p>SE4: I feel confident helping to achieve targets/goals in my department.</p> <p>SE5: I feel confident contacting people outside of the department to discuss learning issues.</p> <p>SE6: I feel confident presenting information to my study colleagues.</p>
Resilience	<p>R2: When mistakes happen to me, I take it as a sign of success.</p> <p>R5: In achieving my learning goals, I have encountered many failures.</p> <p>R6: In learning, I always face various obstacles.</p>
Knowledge Articulation	<p>KA1: Students involved in various parties are regularly asked about their cooperation experience.</p> <p>KA2: Students responsible for cooperation always keep records (in the form of memos, notes, reports, or presentations) of all important activities, decisions or actions related to such cooperation.</p> <p>KA3: Students who follow the cooperation programme regularly report progress and performance regarding their respective cooperation.</p> <p>KA4: Prodi maintains a 'repository' or database containing information from each agency working with it (e.g., date and purpose of establishment of cooperation, name of partners, names of students managing the cooperation, etc.).</p>

KA5: Prodi has a directory or ‘contact list’ of individuals from within or outside the university who have the potential to provide input or assistance to improve the quality of co-management.

Team Strain	TS10: ----- Sem Descrição no artigo -----
	TS11: ----- Sem Descrição no artigo -----
	TS12: ----- Sem Descrição no artigo -----
	TS13: ----- Sem Descrição no artigo -----
	TS14: ----- Sem Descrição no artigo -----
	TS15: ----- Sem Descrição no artigo -----
	TS16: ----- Sem Descrição no artigo -----
	TS17: ----- Sem Descrição no artigo -----
Cooperative Classroom Environment	CCE1: The class is more fun when I study with other friends.
	CCE3: I learn best when with my classmates.
	CCE4: I got better grades when I was studying with other friends.
	CCE5: I prefer taking classes where students learn together to solve problems.
	CCE8: ----- Sem Descrição no artigo -----
	CCE9: ----- Sem Descrição no artigo -----
	CCE10: ----- Sem Descrição no artigo -----
	CCE11: ----- Sem Descrição no artigo -----

Tabela 3: Variáveis descritivas dos estudantes inquiridos⁴

Variável dataset	Descrição
Gender	Sexo dos inquiridos ⁵ (está codificado com 1 ou 2, pelo que não conseguimos saber a qual sexo se refere, pois não temos as etiquetas)
Tlahir	Data de nascimento
BLhair	Em indonésio pode ser uma abreviatura de Bulan Lahir, que significa mês de nascimento. ⁶
Pengeluaran	Em indonésio pode significar despesas. Estes valores estão de 1 a 5 e provavelmente era um item do questionário que pedia aos estudantes para refletirem a sua situação financeira.
Status	Pode corresponder ao estado civil da pessoa, já que tem valores 1 ou 2 e existe uma grande maioria no 2.
Fak	Abreviatura para faculdade que indica a área estudada pelo inquirido
IPK	Do indonésio Indeks Prestasi Kumulatif que representa o GPA (Global Point Average) dos estudantes. Estes valores estão expressivos numa escala discreta de 1 a 4.
Semester	O semestre que frequentam.

⁴O significado pode ser enviesado visto que resultou de uma pesquisa

⁵Embora a tradução direta seja género, os autores estão, na verdade, a referir-se a sexo biológico

⁶Embora incorreta, a codificação desta variável (0–12) é irrelevante, dado que não será considerada na análise.

Anexo B - Análise descritiva dos estudantes inquiridos

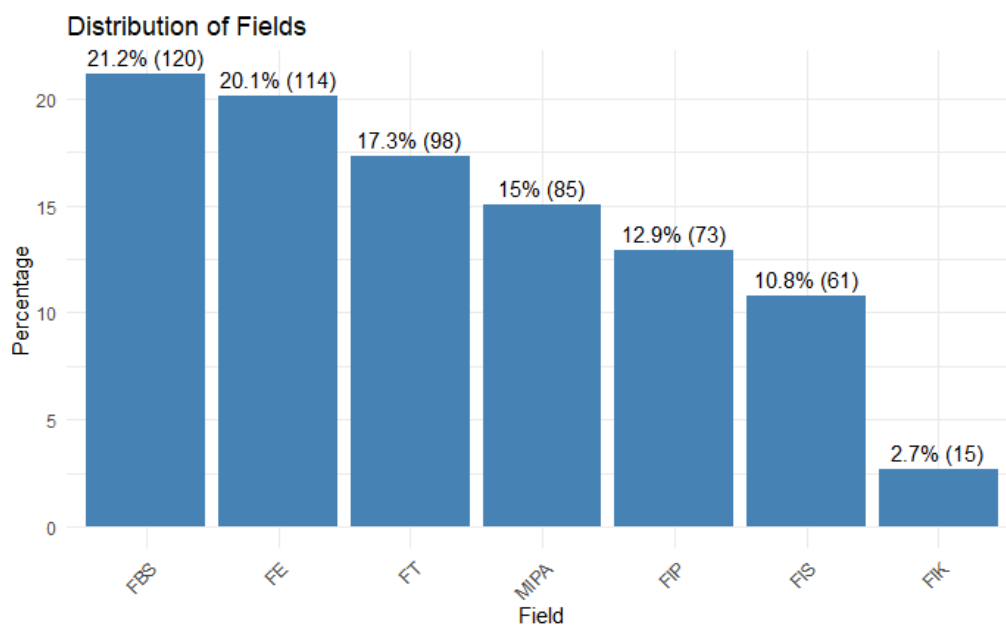


Figura 5: Distribuição de Áreas das faculdades (Fak) dos estudantes inquiridos

A distribuição das áreas confirmam-se com as apresentadas no artigo.




Figura 6: Distribuição de Áreas das faculdades (Fak) dos estudantes inquiridos

Anexo C - Full SEM: replicação do artigo

1ª abordagem: Coeficientes estimados das regressões com os construtos já criados do *dataset*

```
##
## Regressions:
##           Estimate Post.SD pi.lower pi.upper Std.lv Std.all
## Motivation ~
##   Resilience      0.170   0.047   0.079   0.262   0.170   0.149
##   KnowldgArtcltn  -0.249   0.064  -0.376  -0.125  -0.249  -0.180
##   TeamStrain       0.110   0.065  -0.018   0.237   0.110   0.079
##   CoopClass       -0.015   0.067  -0.145   0.117  -0.015  -0.010
## SelfEfficacy ~
##   Resilience      0.133   0.031   0.071   0.195   0.133   0.165
##   KnowldgArtcltn   0.192   0.042   0.110   0.271   0.192   0.197
##   TeamStrain       0.157   0.040   0.078   0.237   0.157   0.160
##   CoopClass        0.203   0.042   0.121   0.286   0.203   0.198
## ethics ~
##   Motivation       0.165   0.051   0.065   0.264   0.165   0.136
##   SelfEfficacy     0.195   0.071   0.057   0.334   0.195   0.113
##   Rhat   Prior
##
##   1.000   normal(0,10)
##   1.000   normal(0,10)
##   1.000   normal(0,10)
##   1.000   normal(0,10)
##
##   1.000   normal(0,10)
##   1.000   normal(0,10)
##   1.000   normal(0,10)
##   1.000   normal(0,10)
##
##   1.000   normal(0,10)
##   1.000   normal(0,10)
##
## Variances:
##           Estimate Post.SD pi.lower pi.upper Std.lv Std.all
##   .Motivation      0.493   0.029   0.439   0.555   0.493   0.957
##   .SelfEfficacy     0.197   0.012   0.176   0.221   0.197   0.765
##   .ethics           0.744   0.044   0.659   0.836   0.744   0.969
##   Rhat   Prior
##   0.999 gamma(1,.5)[sd]
##   0.999 gamma(1,.5)[sd]
##   1.000 gamma(1,.5)[sd]
```

Figura 7: 1ª abordagem: Coeficientes estimados das regressões

2ª abordagem: Coeficientes estimados das regressões com a média das variáveis observadas

```
##
## Regressions:
##               Estimate Post.SD pi.lower pi.upper Std.lv
## mean_factor_Motivation ~
##   men_fctr_Rslnc      0.171   0.046   0.077   0.261   0.171
##   mn_fctr_KnwldA     -0.249   0.064  -0.373  -0.123  -0.249
##   mn_fctr_TmStrn      0.110   0.065  -0.019   0.238   0.110
##   mn_fctr_CprtCE     -0.014   0.068  -0.150   0.118  -0.014
## mean_factor_SelfEfficacy ~
##   men_fctr_Rslnc      0.133   0.031   0.072   0.194   0.133
##   mn_fctr_KnwldA      0.192   0.042   0.109   0.275   0.192
##   mn_fctr_TmStrn      0.158   0.040   0.080   0.235   0.158
##   mn_fctr_CprtCE      0.204   0.041   0.122   0.284   0.204
## mean_factor_Ethics ~
##   men_fctr_Mtvtn      0.166   0.053   0.062   0.270   0.166
##   mn_fctr_SlfEff      0.195   0.070   0.059   0.332   0.195
## Std.all   Rhat   Prior
##
##   0.149   1.000  normal(0,10)
##  -0.180   0.999  normal(0,10)
##   0.079   0.999  normal(0,10)
##  -0.010   1.000  normal(0,10)
##
##   0.165   1.000  normal(0,10)
##   0.196   1.000  normal(0,10)
##   0.161   1.000  normal(0,10)
##   0.198   1.000  normal(0,10)
##
##   0.136   0.999  normal(0,10)
##   0.113   1.000  normal(0,10)
##
## Variances:
##               Estimate Post.SD pi.lower pi.upper Std.lv Std.all
## .men_fctr_Mtvtn    0.493   0.029   0.440   0.554   0.493   0.956
## .mn_fctr_SlfEff    0.197   0.012   0.175   0.222   0.197   0.765
## .men_fctr_Ethics   0.745   0.044   0.665   0.835   0.745   0.969
##   Rhat   Prior
##   1.001 gamma(1,.5)[sd]
##   0.999 gamma(1,.5)[sd]
##   1.000 gamma(1,.5)[sd]
```

Figura 8: 2ª abordagem: Coeficientes estimados das regressões


3ª abordagem: Coeficientes estimados das regressões com os scores das variáveis observadas

```
##
## Regressions:
##               Estimate Post.SD pi.lower pi.upper Std.lv
## score_factor_Motivation ~
##   scr_fctr_Rslnc      0.128  0.038   0.053   0.205   0.128
##   scr_fctr_KnwIA     -0.156  0.043  -0.238  -0.072  -0.156
##   scr_fctr_TmStr      0.061  0.041  -0.019   0.142   0.061
##   scr_fctr_CprCE     -0.015  0.042  -0.100   0.068  -0.015
## score_factor_SelfEfficacy ~
##   scr_fctr_Rslnc      0.168  0.038   0.095   0.244   0.168
##   scr_fctr_KnwIA      0.181  0.042   0.099   0.266   0.181
##   scr_fctr_TmStr      0.176  0.040   0.096   0.254   0.176
##   scr_fctr_CprCE      0.182  0.040   0.103   0.261   0.182
## score_factor_Ethics ~
##   scr_fctr_Mtvtn      0.131  0.048   0.038   0.223   0.131
##   scr_fctr_SlfEf      0.126  0.043   0.041   0.210   0.126
## Std.all      Rhat      Prior
##
##   0.138  0.999  normal(0,10)
##  -0.175  0.999  normal(0,10)
##   0.070  1.000  normal(0,10)
##  -0.017  1.000  normal(0,10)
##
##   0.165  0.999  normal(0,10)
##   0.184  1.000  normal(0,10)
##   0.184  1.000  normal(0,10)
##   0.183  1.000  normal(0,10)
##
##   0.118  0.999  normal(0,10)
##   0.125  1.000  normal(0,10)
##
## Variances:
##               Estimate Post.SD pi.lower pi.upper Std.lv Std.all
## .scr_fctr_Mtvtn  0.673  0.040   0.599   0.756   0.673   0.960
## .scr_fctr_SlfEf  0.651  0.038   0.581   0.728   0.651   0.767
## .scr_fctr_Ethcs  0.843  0.051   0.751   0.948   0.843   0.971
##      Rhat      Prior
## 1.000 gamma(1,.5)[sd]
## 1.000 gamma(1,.5)[sd]
## 1.000 gamma(1,.5)[sd]
```

Figura 9: 3ª abordagem: Coeficientes estimados das regressões

Anexo D - Modelo CFA Global (esquema)

Apesar de não muito perceptível, notamos que estão presentes todos os itens para a formação das variáveis latentes e constam as covariâncias entre estas.



Anexo E - Resultados do modelo SEM todo seguido

1 - Summary do modelo

```
## Estimator BAYES
## Optimization method MCMC
## Number of model parameters 86
##
## Number of observations 566
##
## Statistic MargLogLik PPP
## Value -17811.331 0.000
##
## Parameter Estimates:
##
##
## Latent Variables:
## Estimate Post.SD pi.lower pi.upper
## StudentEthics =~
## ET12 0.880 0.045 0.790 0.959
## ET13 0.691 0.042 0.613 0.776
## Motivation =~
## Mot5 0.555 0.044 0.466 0.641
## Mot8 0.589 0.045 0.502 0.681
## Mot11 0.572 0.045 0.486 0.666
## SelfEfficacy =~
## SE1 0.354 0.025 0.307 0.403
## SE2 0.369 0.027 0.317 0.421
## SE3 0.428 0.024 0.383 0.476
## SE4 0.406 0.023 0.361 0.451
## SE5 0.363 0.025 0.316 0.411
## SE6 0.385 0.022 0.343 0.430
## Resilience =~
## R2 0.409 0.036 0.342 0.488
## R5 0.682 0.036 0.610 0.752
## R6 0.568 0.035 0.502 0.642
## KnowledgeArticulation =~
## KA1 0.477 0.026 0.427 0.530
## KA2 0.530 0.024 0.483 0.576
## KA3 0.480 0.023 0.436 0.525
## KA4 0.515 0.023 0.471 0.560
## KA5 0.447 0.025 0.400 0.498
## TeamStrain =~
## TS10 0.483 0.029 0.428 0.538
## TS11 0.489 0.028 0.435 0.543
## TS12 0.505 0.029 0.447 0.561
## TS13 0.511 0.023 0.467 0.556
## TS14 0.522 0.021 0.482 0.563
## TS15 0.560 0.021 0.519 0.600
## TS16 0.453 0.021 0.410 0.497
## TS17 0.444 0.020 0.405 0.485
##
## CooperativeClassroomEnvironment =~
## CCE1 0.493 0.030 0.434 0.556
## CCE3 0.420 0.032 0.360 0.484
## CCE4 0.405 0.030 0.348 0.464
## CCE5 0.444 0.026 0.395 0.495
## CCE8 0.425 0.031 0.367 0.487
## CCE9 0.510 0.028 0.455 0.566
## CCE10 0.482 0.026 0.433 0.533
## CCE11 0.498 0.027 0.447 0.551
```



```

##      Std.lv  Std.all    Rhat    Prior
##
##      0.906    0.961    1.008    normal(0,10)
##      0.711    0.761    1.008    normal(0,10)
##
##      0.576    0.653    1.001    normal(0,10)
##      0.612    0.669    1.004    normal(0,10)
##      0.594    0.639    1.000    normal(0,10)
##
##      0.425    0.592    1.004    normal(0,10)
##      0.444    0.579    1.002    normal(0,10)
##      0.515    0.764    1.002    normal(0,10)
##      0.488    0.731    1.002    normal(0,10)
##      0.436    0.631    1.006    normal(0,10)
##      0.464    0.713    1.005    normal(0,10)
##
##      0.409    0.523    1.006    normal(0,10)
##      0.682    0.851    1.002    normal(0,10)
##      0.568    0.749    1.009    normal(0,10)
##
##      0.477    0.703    1.005    normal(0,10)
##      0.530    0.816    1.001    normal(0,10)
##      0.480    0.776    1.004    normal(0,10)
##      0.515    0.803    1.002    normal(0,10)
##      0.447    0.704    1.004    normal(0,10)
##
##      0.483    0.656    1.006    normal(0,10)
##      0.489    0.658    1.002    normal(0,10)
##      0.505    0.670    1.001    normal(0,10)
##      0.511    0.790    1.004    normal(0,10)
##      0.522    0.860    1.003    normal(0,10)
##      0.560    0.885    1.002    normal(0,10)
##      0.453    0.772    1.002    normal(0,10)
##      0.444    0.769    1.002    normal(0,10)
##
##      0.493    0.658    1.002    normal(0,10)
##      0.420    0.547    1.000    normal(0,10)
##      0.405    0.560    1.000    normal(0,10)
##      0.444    0.686    1.002    normal(0,10)
##      0.425    0.573    1.006    normal(0,10)
##      0.510    0.706    1.004    normal(0,10)
##      0.482    0.731    1.002    normal(0,10)
##      0.498    0.723    1.000    normal(0,10)

## Regressions:
##      Estimate  Post.SD  pi.lower  pi.upper  Std.lv  Std.all
## Motivation ~
## Resilience    0.198    0.063    0.076    0.320    0.190    0.190
## KnowldgArtcltn -0.251    0.074    -0.401   -0.113   -0.241   -0.241
## TeamStrain     0.126    0.067    0.001    0.259    0.122    0.122
## CpirtvClssrmEnv -0.027    0.067    -0.154    0.105   -0.026   -0.026
## SelfEfficacy ~
## Resilience    0.229    0.056    0.122    0.338    0.190    0.190
## KnowldgArtcltn 0.257    0.067    0.126    0.390    0.214    0.214
## TeamStrain     0.227    0.062    0.108    0.350    0.189    0.189
## CpirtvClssrmEnv 0.249    0.065    0.121    0.379    0.207    0.207
## StudentEthics ~
## Motivation     0.204    0.054    0.097    0.308    0.206    0.206
## SelfEfficacy   0.105    0.042    0.023    0.190    0.123    0.123
## Rhat          Prior
##
##      1.001    normal(0,10)
##      1.000    normal(0,10)
##      1.002    normal(0,10)
##      1.004    normal(0,10)
##
##      1.001    normal(0,10)
##      1.000    normal(0,10)
##      1.003    normal(0,10)
##      1.002    normal(0,10)
##
##      1.003    normal(0,10)
##      1.001    normal(0,10)

```

```

## Covariances:
##
##      Estimate Post.SD pi.lower pi.upper Std.lv
## Resilience ~
##   KnowldgArtcltn      0.185    0.050    0.085    0.281    0.185
##   TeamStrain          0.169    0.047    0.076    0.261    0.169
##   CprrtvClssrmEnv     0.154    0.052    0.051    0.252    0.154
## KnowledgeArticulation ~
##   TeamStrain          0.473    0.038    0.399    0.546    0.473
##   CprrtvClssrmEnv     0.446    0.039    0.367    0.519    0.446
## TeamStrain ~
##   CprrtvClssrmEnv     0.402    0.041    0.320    0.482    0.402
## Std.all      Rhat      Prior
##
##   0.185    1.001    lkj_corr(1)
##   0.169    1.001    lkj_corr(1)
##   0.154    1.004    lkj_corr(1)
##
##   0.473    1.002    lkj_corr(1)
##   0.446    1.001    lkj_corr(1)
##
##   0.402    1.000    lkj_corr(1)

## Variances:
##      Estimate Post.SD pi.lower pi.upper Std.lv Std.all
## .ET12      0.069    0.065    0.000    0.216    0.069    0.077
## .ET13      0.368    0.048    0.251    0.444    0.368    0.421
## .Mot5      0.448    0.045    0.364    0.546    0.448    0.574
## .Mot8      0.463    0.047    0.364    0.557    0.463    0.553
## .Mot11     0.513    0.047    0.427    0.612    0.513    0.592
## .SE1       0.335    0.022    0.293    0.383    0.335    0.649
## .SE2       0.390    0.027    0.342    0.447    0.390    0.664
## .SE3       0.190    0.015    0.161    0.221    0.190    0.417
## .SE4       0.208    0.016    0.179    0.240    0.208    0.466
## .SE5       0.287    0.020    0.251    0.329    0.287    0.601
## .SE6       0.208    0.016    0.179    0.240    0.208    0.492
## .R2        0.444    0.030    0.388    0.507    0.444    0.726
## .R5        0.177    0.034    0.109    0.243    0.177    0.276
## .R6        0.252    0.027    0.201    0.307    0.252    0.439
## .KA1       0.233    0.016    0.203    0.266    0.233    0.506
## .KA2       0.142    0.012    0.119    0.166    0.142    0.335
## .KA3       0.152    0.011    0.131    0.175    0.152    0.398
## .KA4       0.146    0.011    0.126    0.170    0.146    0.356
## .KA5       0.204    0.014    0.179    0.234    0.204    0.505
## .TS10      0.309    0.020    0.272    0.350    0.309    0.570
## .TS11      0.313    0.020    0.277    0.353    0.313    0.567
## .TS12      0.314    0.020    0.277    0.354    0.314    0.551
## .TS13      0.157    0.011    0.137    0.180    0.157    0.375
## .TS14      0.096    0.007    0.083    0.111    0.096    0.261
## .TS15      0.087    0.007    0.074    0.102    0.087    0.218
## .TS16      0.139    0.010    0.122    0.159    0.139    0.405
## .TS17      0.136    0.009    0.119    0.155    0.136    0.408
## .CCE1      0.319    0.022    0.278    0.365    0.319    0.567
## .CCE3      0.414    0.026    0.366    0.467    0.414    0.701
## .CCE4      0.359    0.024    0.314    0.409    0.359    0.686
## .CCE5      0.222    0.016    0.193    0.254    0.222    0.529
## .CCE8      0.370    0.024    0.326    0.420    0.370    0.672
## .CCE9      0.262    0.019    0.228    0.301    0.262    0.502
## .CCE10     0.202    0.015    0.175    0.232    0.202    0.465
## .CCE11     0.226    0.017    0.195    0.261    0.226    0.478
## .StudentEthics 1.000
## .Motivation    1.000
## .SelfEfficacy  1.000
## Resilience    1.000
## KnowldgArtcltn 1.000
## TeamStrain     1.000
## CprrtvClssrmEnv 1.000

```



```

##      Rhat      Prior
##      1.014 gamma(1,.5)[sd]
##      1.017 gamma(1,.5)[sd]
##      1.003 gamma(1,.5)[sd]
##      1.004 gamma(1,.5)[sd]
##      1.003 gamma(1,.5)[sd]
##      1.002 gamma(1,.5)[sd]
##      1.004 gamma(1,.5)[sd]
##      1.003 gamma(1,.5)[sd]
##      1.002 gamma(1,.5)[sd]
##      1.007 gamma(1,.5)[sd]
##      1.003 gamma(1,.5)[sd]
##      1.000 gamma(1,.5)[sd]
##      1.001 gamma(1,.5)[sd]
##      1.002 gamma(1,.5)[sd]
##      1.003 gamma(1,.5)[sd]
##      1.003 gamma(1,.5)[sd]
##      1.002 gamma(1,.5)[sd]
##      1.002 gamma(1,.5)[sd]
##      1.002 gamma(1,.5)[sd]
##      1.001 gamma(1,.5)[sd]
##      1.003 gamma(1,.5)[sd]
##      1.003 gamma(1,.5)[sd]
##      1.002 gamma(1,.5)[sd]
##      1.002 gamma(1,.5)[sd]
##      1.001 gamma(1,.5)[sd]
##      1.001 gamma(1,.5)[sd]
##      1.001 gamma(1,.5)[sd]
##      1.002 gamma(1,.5)[sd]
##      1.002 gamma(1,.5)[sd]
##      1.004 gamma(1,.5)[sd]
##      1.005 gamma(1,.5)[sd]
##      1.002 gamma(1,.5)[sd]
##      1.002 gamma(1,.5)[sd]
##      1.000 gamma(1,.5)[sd]
##      1.001 gamma(1,.5)[sd]

## R-Square:
##      Estimate
##      ET12      0.923
##      ET13      0.579
##      Mot5       0.426
##      Mot8       0.447
##      Mot11      0.408
##      SE1        0.351
##      SE2        0.336
##      SE3        0.583
##      SE4        0.534
##      SE5        0.399
##      SE6        0.508
##      R2         0.274
##      R5         0.724
##      R6         0.561
##      KA1        0.494
##      KA2        0.665
##      KA3        0.602
##      KA4        0.644
##      KA5        0.495
##      TS10       0.430
##      TS11       0.433
##      TS12       0.449
##      TS13       0.625
##      TS14       0.739
##      TS15       0.782
##      TS16       0.595
##      TS17       0.592
##      CCE1       0.433
##      CCE3       0.299
##      CCE4       0.314
##      CCE5       0.471
##      CCE8       0.328
##      CCE9       0.498
##      CCE10      0.535
##      CCE11      0.522
##      StudentEthics 0.057
##      Motivation 0.075
##      SelfEfficacy 0.309

```

2 - Distribuição da *posterior* para ET12 e Mot8



3 - BRMSEA, GammaHat, AdjBGammaHat

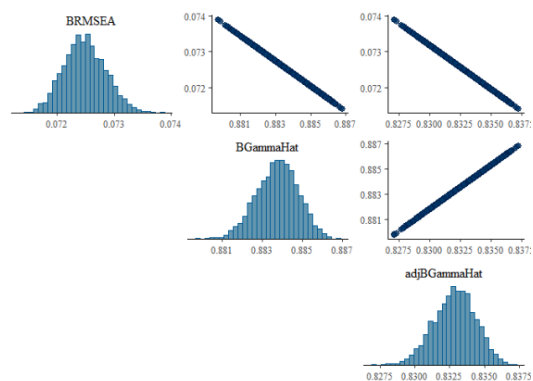
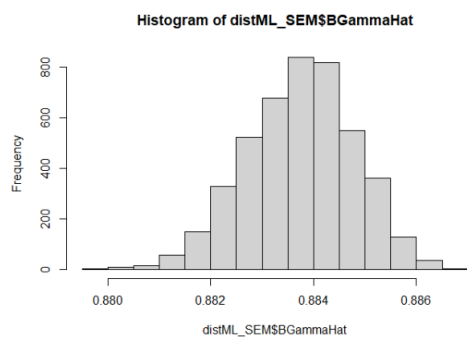


Figura 20: Regressões entre construtos